Predictor de precios de aguacate en Estados unidos

Lizeth Fernanda Ropero Cárdenas -2204001 Juan Camilo Guerrero Ortega - 2183266 Faiber Stiven Angarita Mendoza - 2191963

Contenidos

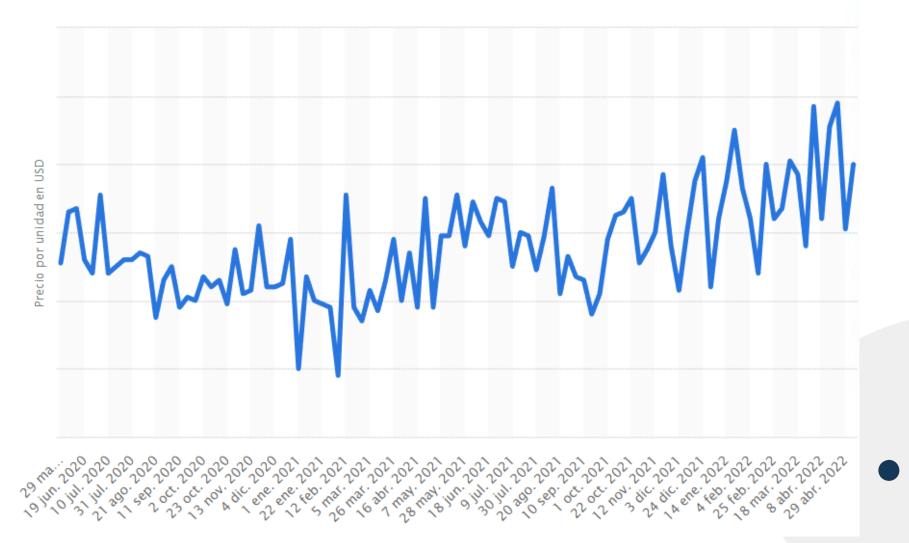
Planteamiento del problema

2 Objetivos

3 Modelos 4 Conclusiones

Planteamiento del problema

Nuestro problema se basa en las fluctuaciones en los precios del aguacate en USA, estas fluctuaciones generan problemas de sobreproducción y escases afectando a empresas y comunidades que no pueden acceder al alimento.



2 Objetivo general

 Desarrollar un sistema de lA basado en modelos de aprendizaje que pueda predecir el precio del aguacate

Objetivo especificos

- Entrenar varios modelos basados en regresión lineal, para comparar y obtener el mejor prediciendo el precio del aguacate
- Predecir el precio de los aguacates a partir de los datos proporcionados por el dataset en Estados Unidos

Dataset utilizado

https://www.kaggle.com/datasets/neuromusic/avocado-prices

4046 : Aguacate Hass estándar

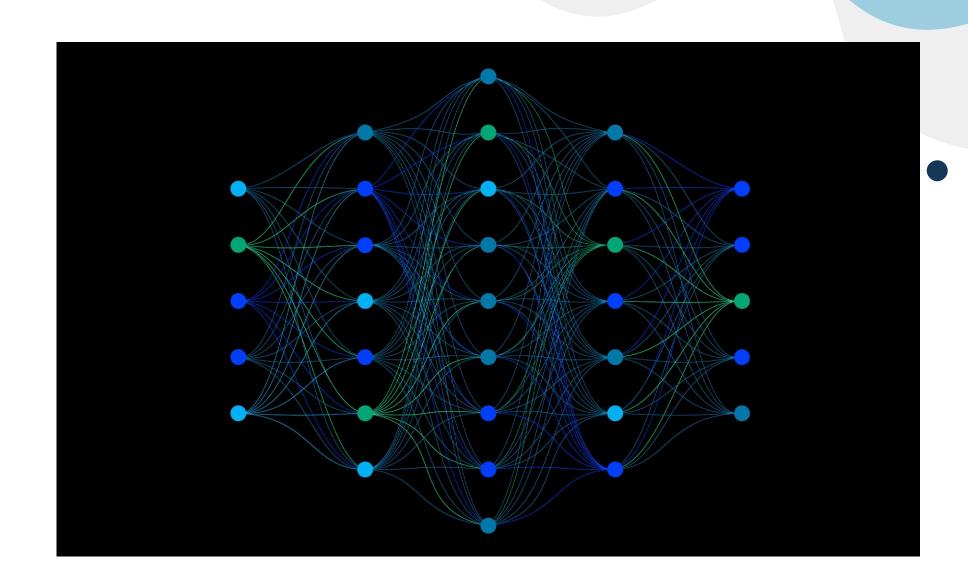
4225: Aguacate Hass grande

4770: Fuerte. Bacon, Zutano



Modelos

- Decision Tree Regressor
- Random Forest Regressor
 - Redes neuronales-Standard Scaler-Dropout



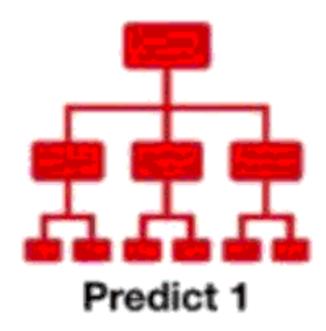
Decision Tree Regressor

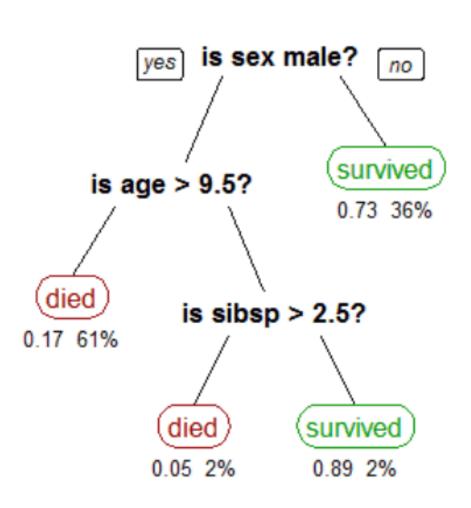
```
s = cross_val_score(regressor, np.array([df_avocado['Total Volume']]).T, df_avocado['AveragePrice'], cv=KFold(10, shuffle=True), scoring=make_scorer(mean_squared_error) print ("MSE depth: 2 %.3f (+/- %.5f)"%(np.mean(s), np.std(s)))

s = cross_val_score(regressorSA, np.array([df_avocado['Total Volume']]).T, df_avocado['AveragePrice'], cv=KFold(10, shuffle=True), scoring=make_scorer(mean_squared_error) print ("MSE depth: 30 %.3f (+/- %.5f)"%(np.mean(s), np.std(s)))
```

depth: 2 0.105 (+/- 0.00367) depth: 30 0.109 (+/- 0.00461)

> Tiempo de ejecución 5 segundos y Max Depth de 2 y 10





Random Forest Regressor

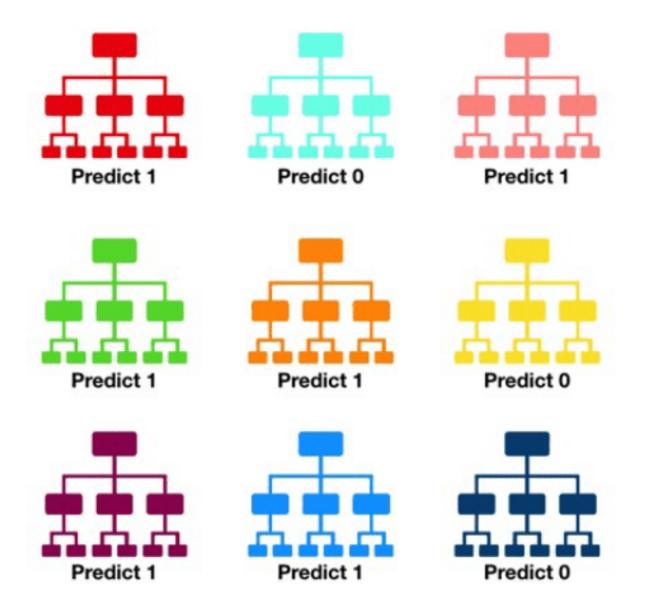
```
1 s = cross_val_score(regressor_1, np.array([df_avocado['Total Volume']]).T, df_avocado['AveragePrice'], cv=KFold(10, shuffle=True), scoring=make_scorer(mean_squared_error))
2 print ("MSE depth: 1 %.3f (+/- %.5f)"%(np.mean(s), np.std(s)))
3
4 s = cross_val_score(regressor_6, np.array([df_avocado['Total Volume']]).T, df_avocado['AveragePrice'], cv=KFold(10, shuffle=True), scoring=make_scorer(mean_squared_error))
5 print ("MSE depth: 6 %.3f (+/- %.5f)"%(np.mean(s), np.std(s)))
```

MSE depth: 1 0.110 (+/- 0.00197) MSE depth: 6 0.102 (+/- 0.00349)

Tiempo de ejecución 22 segundos

Max depth de 1 y 6

Random State de 100



Red neuronal Sencilla

Tiempo de ejecución 53 segundos

1.layers.Dense(128, activation='relu',)
2.layers.Dense(64, activation='relu'),
3.layers.Dense(1)

```
Epoch 37/50
Epoch 38/50
Epoch 39/50
Epoch 40/50
Epoch 42/50
Epoch 43/50
Epoch 44/50
Epoch 45/50
Epoch 46/50
Epoch 47/50
Epoch 48/50
Epoch 49/50
Epoch 50/50
Test MSE: 16214.705078125
```

Red neuronal usando StandardScaler

Tiempo de ejecución 1 minuto 25 segundos

1.layers.Dense(128, 2.activation='relu') 3.layers.Dense(64, activation='relu') 4.layers.Dense(1)

```
Epoch 34/50
Epoch 35/50
Epoch 36/50
Epoch 37/50
Epoch 38/50
Epoch 39/50
Epoch 40/50
Epoch 41/50
Epoch 42/50
Epoch 43/50
Epoch 44/50
Epoch 45/50
Epoch 46/50
Epoch 48/50
Epoch 49/50
Test MSE: 1.1835090845124796e-05
```

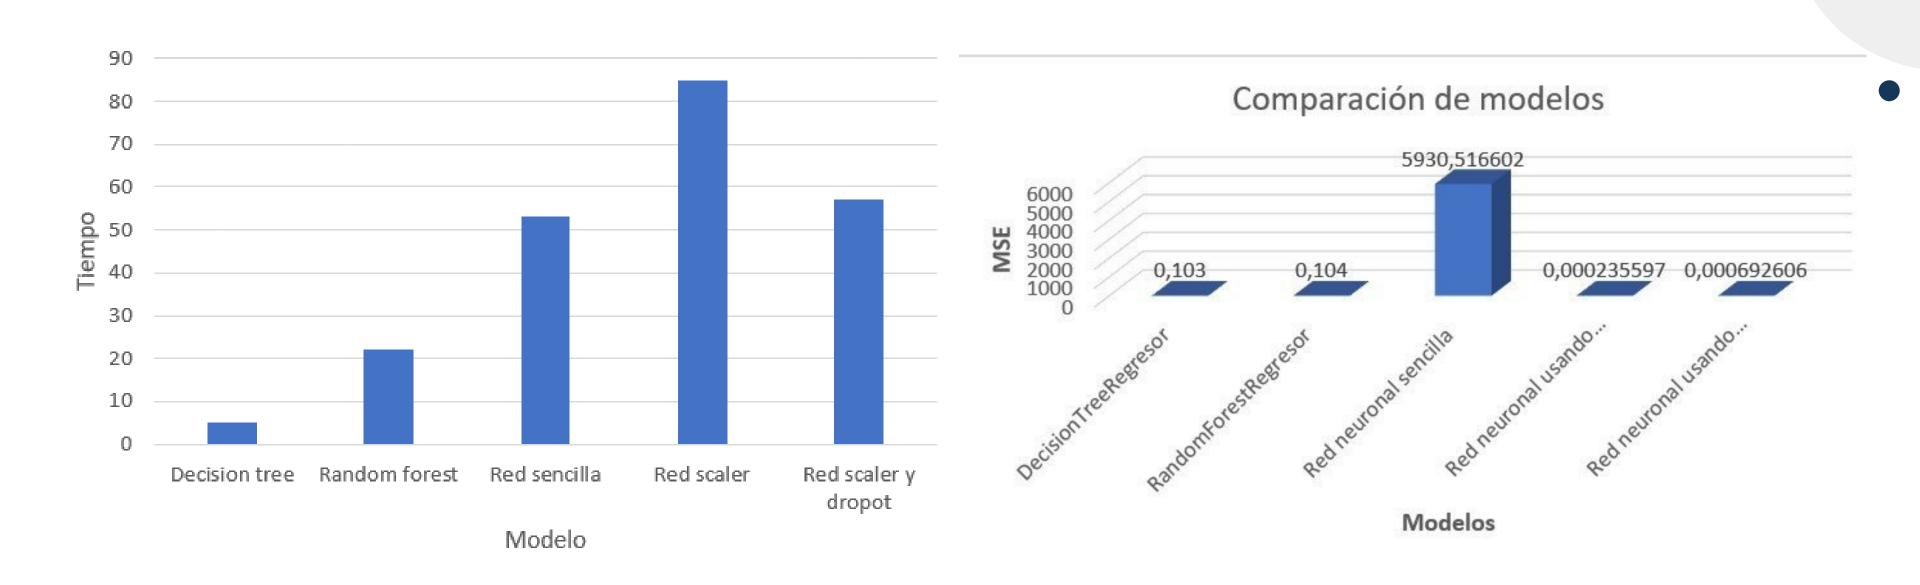
Red neuronal usando StandardScaler y Dropout

Tiempo de ejecución 57 segundos

1.layers.Dense(128, activation='relu') 2.layers.Dropout(0.2) 3.layers.Dense(64, 4.activation='relu') 5.layers.Dropout(0.2) 6.layers.Dense(1)

```
---,--- L
Epoch 38/50
Epoch 39/50
Epoch 40/50
Epoch 41/50
Epoch 42/50
Epoch 43/50
Epoch 44/50
Epoch 45/50
Epoch 46/50
Epoch 47/50
Epoch 48/50
Epoch 49/50
Epoch 50/50
Test MSE: 0.0001988701696973294
```

Comparativa entre los modelos



Conclusión

Mediante el entrenamiento de diferentes modelos se puede concluir que el mejor son las redes neuonales usando StandardScaler y Dropout.

Gracias!

